

FlagOS推理框架

部门：AI框架研发组

姓名：吕梦思


日期：2026.8.5

FlagOS: 面向多种AI芯片的全栈开源技术




基于FlagOS多芯片统一后端的vLLM

<https://github.com/vllm-project/vllm/issues/9268>




vLLM多后端v1版本：代码中对硬件相关代码抽象

<https://github.com/vllm-project/vllm/issues/11162>



vLLM多后端v2版本：基于Python EntryPoint机制的插件

vLLM多后端FlagOS版本：



- 以Out-Of-Tree的方式把FlagOS作为虚拟后端按照vLLM的Plugin规范接入vLLM。
- 利用FlagOS多芯片后端优势，尽可能实现框架层面硬件无关代码统一。
- 不同芯片上用户将使用相同vllm版本。
- 利用PyTorch的图层Pass优化机制实现不同芯片的自定义融合等优化。

Upstream: vLLM Inference Framework

OpenAI / LLM API AsyncLLM Engine Scheduler KV Cache PagedAttention

entry_points

vLLM-Plugin-FL (OOT Mechanism)

FLPlatform

Boostraps all backend components

Worker Override
(Custom Worker)

ModelRunner
Override
(Model Execution)

Compilation
Override
(Platform/Device)

Communicator
(FlagCX Collective)

Yaml Config
(Backend & Op config)

OpManager
(Unified Operator
Registry)

Operator Dispatch
(FlagGems, Vender,
reference)

IO Dump
(debug toolkit)


英伟达GPU

华为NPU

平头哥PPU

...

Operator Dispatch



	NVIDIA	Ascend	MetaX	T-HEAD	lluvatar	Hygon	Moore Threads	KunLunXin	Sunrise	Tsingmicro	Enflame
芯片支持	☑	☑	☑	☑	☑	☑	☑	☑	☑	☑	🚧

Upstream: SGLang Inference Framework

entry point

ATen Ops
 (FlagGems 500+ ops)

Fused Kernels
 (AROUND Hook Dispatch)

Communication
 (FlagCX Collective)

YAML Config
 Op Config

OpManager: flaggems > vendor > reference (priority dispatch)

Phase 2: Roadmap

SGLang/vLLM
 Dual-Framework Plugin

Shape-Aware
 Dynamic Dispatch

PD Disaggregation
 (Multi-Chip Scheduling)

IO Inspector
 (Precision/Perf Debug)

Multi-Chip Hardware


NVIDIA
 (CUDA)

华为 Ascend
 (NPU)

摩尔线程
 (MUSA)

...

Operator Dispatch



	NVIDIA	Ascend	MetaX	T-HEAD	lluvatar	Hygon	Moore Threads	KunLunXin	Sunrise	Tsingmicro	Enflame
芯片支持	☑	☑	🚧	☑	🚧	🚧	☑	🚧	🚧	🚧	🚧


预计8月中会完成现有芯片的接入


- 第一阶段：
 - 厂商定制版vllm/sglang+vllm/sglang-plugin-fl
- 第二阶段（现阶段）：
 - 全面支持解耦厂商定制版，支持empty版本的vllm/sglang + vllm/sglang-plugin-fl
 - 和sglang 社区共建empty模式

【端到端优化】

- 通用pass支持
- 异步调度策略优化
- MoE & Attention模块协同优化
- 国产统一量化框架：
 - 开发model-free的量化框架，进行module level模型权重量化与量化还原，解决国产芯片不能支持低比特浮点数模型推理的问题。

- 自动遍历模型算子，基于3种后端构建算子搜索空间
- 通过端到端模型基准测试，自动生成最优算子配置，实现最佳吞吐






- 自动调优后
moe_align_block_size 算子选择
cuda版本，可以实现端到端性能
提升3%-4.6%。
- 自动调优对端到端性能提升有明
显收益。

算子版本	算子名称	耗时占比
cuda	vllm::moe::moe_align_block_size_kernel	2.5%
FlagGems	moe_align_block_size_stage1 moe_align_block_size_stage2 moe_align_block_size_stage3 moe_align_block_size_stage4	21.7%

- 通过timeline分析模型算子情况，
发现FlagGems版本的moe align
算子在端到端性能中耗时占比大。



构建“底层能力建设 -> 模型规模验证/性能优化 -> 问题反馈优化 -> 更多模型支持”的闭环机制，降低多芯片生态扩展成本。

★ 框架迭代版本

- 第一阶段：
 - 厂商定制版vllm/sglang+vllm/sglang-plugin-fl
- 第二阶段（现阶段）：
 - 全面支持解耦厂商定制版，支持empty版本的vllm/sglang + vllm/sglang-plugin-fl
 - 和Sglang 社区共建empty模式

序号	模型名	模型发布时间	智源PR发布时间	day0适配	文章标题	文章链接（外部）
8	GLM5.2	2026年06月17日	2026年06月18日		FlagOS Day 0 跨芯适配 GLM-5.2：发布即覆盖四款芯片，支持 vLLM + SGLang双插件	https://mp.weixin.qq.com/s/vsMZYWZacyGNnLflTeiOIA
7	MiniMax M3	2026年06月13日	2026年06月13日		Day0 适配 MiniMax M3：FlagOS × SGLang 首次跨芯发布	https://mp.weixin.qq.com/s/qvykQzFFCpcProN_jldlBQ
6	MiniCPM5-1B	2026年05月26日	2026年05月26日		FlagOS助力 MiniCPM5 在9款芯片（含ARM）适配，Day0实现从云到端生态覆盖，效率追平NVIDIA原生	https://mp.weixin.qq.com/s/Bc7kPUDtRFml-7aGxLK_WA
5	混元MT2（Hy-MT2）	2026年05月21日	2026年05月21日		众智FlagOS完成腾讯混元MT2多语翻译模型全系列多芯片适配：英伟达/华为/平头哥三芯开箱即用 https://modelscope.cn/models/FlagRelease/Qwen3.6-35B-A3B-nomtp-metax-FlagOS-Express	https://mp.weixin.qq.com/s/oO64IBzI6FNo9BeV3YX5FA
4	Qwen3.6-35B-A3B	2026年04月16日	2026年04月17日		24小时不到，七芯已上！Qwen3.6-35B-A3B发布即获众智FlagOS全速护航	https://mp.weixin.qq.com/s/3aPeH-8mcPTOdNDdETKJOw
3	MiniMax M2.7	2026年04月12日	2026年04月12日		Day 0 实现 MiniMax M2.7 六芯落地，众智FlagOS 又双叒叕让大模型多芯可用了！	https://mp.weixin.qq.com/s/Aam1-Q2bA8hZXUDpHqm3HA
2	Qwen3.5	2026年2月16日（除夕）	2026年03月22日	-	Qwen3.5 多模态MoE模型五款芯片版本齐发，众智FlagOS让大模型“一次发布，多芯可用”	https://mp.weixin.qq.com/s/QGa9tVMqOVaWZguyJpAf-g
1	Qwen3.5 397B	2026年2月16日（除夕）	2026年02月20日	-	众智FlagOS实现千问Qwen3.5 397B MoE模型多芯版统一发布，下载可用	https://mp.weixin.qq.com/s/hjYK19ZvWYHsNRHcDSFDXA

评估结果

基准测试结果

指标	Qwen3.6-35B-A3B-nomtp-Nvidia-Origin	Qwen3.6-35B-A3B-nomtp-Metax-FlagOS
GPQA_Diamond	0.8283	0.803
ERQA	0.5875	0.6

性能基准测试结果

指标	1k&1k 64 并发	4k&1k 64 并发	16k&1k 64 并发	64k&1k 64 并发
等效算力比 (FlagOS/H100)	136.94%	125.03%	113.468%	87.97%